



## 主成分分析

# 主成分分析 (Principal Component Analysis, PCA)

---

正交属性空间中的样本点，如何使用一个超平面对所有样本进行恰当的表达？




# 主成分分析 (Principal Component Analysis, PCA)

---

正交属性空间中的样本点，如何使用一个超平面对所有样本进行恰当的表达？

若存在这样的超平面，那么它大概应具有这样的性质：

- 最大可分性：样本点在这个超平面上的投影能尽可能分开
- 最近重构性：样本点到这个超平面的距离都足够近



主成分分析的两种等价推导

对样本进行中心化：
$$\sum_i \mathbf{x}_i = \mathbf{0}$$

# PCA - 最大可分性

样本点  $\mathbf{x}_i$  在新空间中超平面上的投影是  $\mathbf{W}^T \mathbf{x}_i$ ，若所有样本点的投影能尽可能分开，则应该使得投影后样本点的方差最大化


投影后样本点的方差是  $\sum_i \mathbf{W}^T \mathbf{x}_i \mathbf{x}_i^T \mathbf{W}$

于是：

$$\max_{\mathbf{W}} \quad \text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W})$$
$$\text{s.t.} \quad \mathbf{W}^T \mathbf{W} = \mathbf{I}.$$

等价于：

$$\min_{\mathbf{W}} \quad -\text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W})$$
$$\text{s.t.} \quad \mathbf{W}^T \mathbf{W} = \mathbf{I}.$$



# PCA 求解

$$\begin{array}{ll} \max_{\mathbf{W}} & \text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W}) \\ \text{s.t.} & \mathbf{W}^T \mathbf{W} = \mathbf{I}. \end{array}$$

使用拉格朗日乘子法可得

$$\mathbf{X} \mathbf{X}^T \mathbf{W} = \lambda \mathbf{W}.$$

只需对协方差矩阵  $\mathbf{X} \mathbf{X}^T$  进行特征值分解，并将求得的特征值排序： $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$ ，再取前  $d'$  个特征值对应的特征向量构成  $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'})$ ，这就是主成分分析的解

关键变量：子空间方差

# PCA - 最近重构性

对样本进行中心化:  $\sum_i \mathbf{x}_i = \mathbf{0}$

假定投影变换后得到的新坐标系为  $\{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_d\}$ , 其中  $\mathbf{w}_i$  是标准正交基向量

$$\|\mathbf{w}_i\|_2 = 1, \mathbf{w}_i^T \mathbf{w}_j = 0 (i \neq j).$$

若丢弃新坐标系中的部分坐标, 即将维度降低到  $d' < d$ , 则样本点在低维坐标系中的投影是  $\mathbf{z}_i = (z_{i1}; z_{i2}; \dots; z_{id'})$   $z_{ij} = \mathbf{w}_j^T \mathbf{x}_i$

若基于  $\mathbf{z}_i$  来重构  $\mathbf{x}_i$ , 则会得到  $\hat{\mathbf{x}}_i = \sum_{j=1}^{d'} z_{ij} \mathbf{w}_j$ .

## PCA - 最近重构性 (续)

原样本点  $\mathbf{x}_i$  与基于投影重构的样本点  $\hat{\mathbf{x}}_i$  之间的距离为

$$\begin{aligned} \sum_{i=1}^m \left\| \sum_{j=1}^{d'} z_{ij} \mathbf{w}_j - \mathbf{x}_i \right\|_2^2 &= \sum_{i=1}^m \mathbf{z}_i^T \mathbf{z}_i - 2 \sum_{i=1}^m \mathbf{z}_i^T \mathbf{W}^T \mathbf{x}_i + \text{const} \\ &\propto -\text{tr} \left( \mathbf{W}^T \left( \sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T \right) \mathbf{W} \right). \end{aligned}$$

$\mathbf{w}_j$  是正交基,  $\sum_i \mathbf{x}_i \mathbf{x}_i^T$  是协方差矩阵, 于是由最近重构性, 有:


$$\begin{aligned} \min_{\mathbf{W}} \quad & -\text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W}) \\ \text{s.t.} \quad & \mathbf{W}^T \mathbf{W} = \mathbf{I}. \end{aligned}$$

**关键变量：重构误差**

这就是主成分分析的优化目标

# PCA - FDA



**PCA**是无监督学习方法，而**FDA**是监督学习方法，考虑了标记的作用。





# PCA 应用

协方差矩阵易受到特征尺度影响



通过对数据进行标准化，使所有特征在同一尺度上


# PCA 应用

$d'$  的设置:

□ 用户指定

□ 通过重构误差判断 ?

$$\sum_{i=1}^m \|x_i - \hat{x}_i\|_2^2$$





模型越复杂，重构误差越低

# PCA 应用

$d'$  的设置:

- ❑ 用户指定
- ❑ 在低维空间中对k近邻或其他分类器进行交叉验证
- ❑ 设置重构阈值, 例如  $t=95\%$ , 然后选取最小的  $d'$  使得

$$\frac{\sum_{i=1}^{d'} \lambda_i}{\sum_{i=1}^d \lambda_i} \geq t.$$




# PCA 应用 (续)

PCA 是最常用的降维方法，在不同领域有不同的称谓



例如在人脸识别中该技术被称为“特征脸”(eigenface)

因为若将前  $d'$  个特征值对应的特征向量还原为图像，则得到



降维体现在哪里？

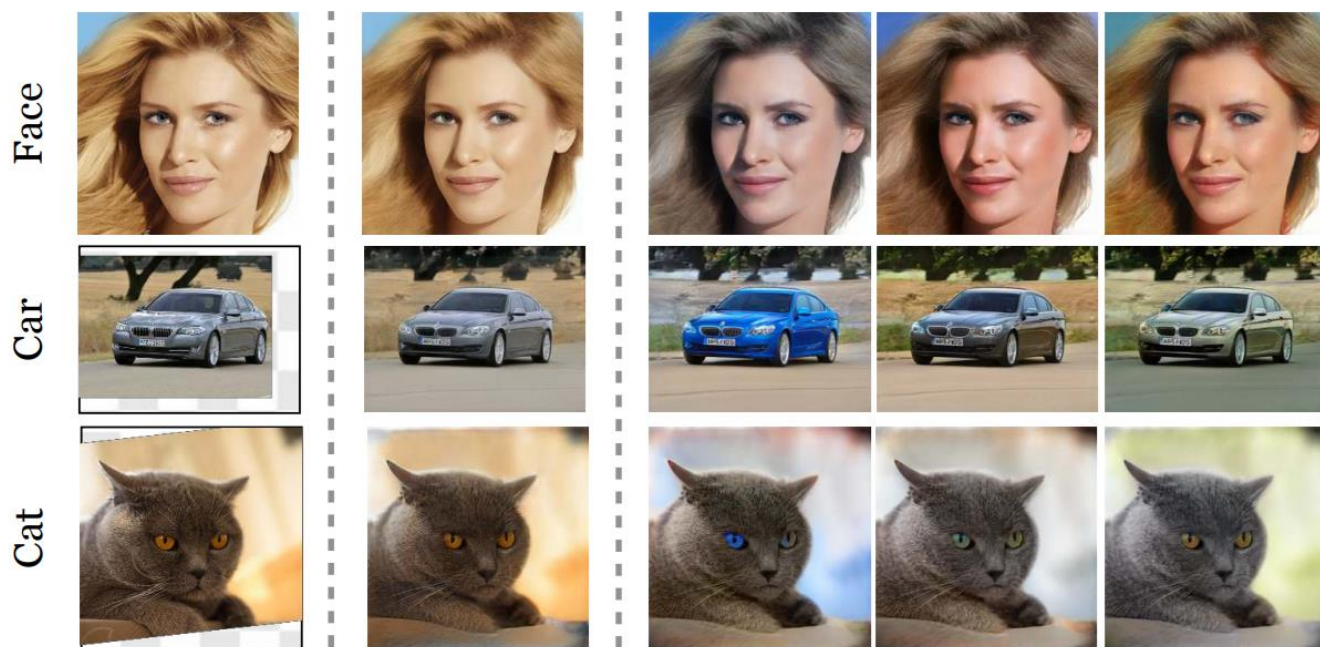
# PCA 应用 (续)



$$\hat{f}(\lambda) = \boxed{3} + \lambda_1 \cdot \boxed{3} + \lambda_2 \cdot \boxed{3}.$$

## PCA 应用 (续)

PCA 可有效降低模型的自由度，可用于实现高维空间中的数据分析 and 可视化。



在前  $d'$  主成分方向进行随机扰动，从而实现通过较少的参数控制高维空间中图像风格的变化

# PCA 的拓展1 – 自编码

---

从减小重构误差角度理解PCA

$$\min_{W^T W = I} \sum_{i=1}^m \|x_i - W z_n\|_2^2 = \sum_{i=1}^m \|x_i - \textcolor{blue}{W} \textcolor{red}{W}^T x_i\|_2^2$$

对W的形式进行推广

$$\min_{f, g} \sum_{i=1}^m \|x_i - \textcolor{blue}{g} \circ \textcolor{red}{f}(x_i)\|_2^2 = \sum_{i=1}^m \|x_i - \textcolor{blue}{decoder} \circ \textcolor{red}{encoder}(x_i)\|_2^2$$

## PCA 的拓展2 – Robust PCA

- PCA的解是基于协方差的特征向量，记为 $\Sigma \propto X^T X = U_\Sigma \Lambda_\Sigma U_\Sigma^T$
- $X$ 的奇异值分解记为 $X \approx U_X S_X V_X^T$

PCA的优化目标可改写为

$$\min_{rank(\hat{X})=d'} \|X - \hat{X}\|_2^2$$

Robust PCA

$$\min_{\hat{X}} \|X - \hat{X}\|_0 + rank(\hat{X})$$




$$\min_{\hat{X}} \|X - \hat{X}\|_1 + \|\hat{X}\|_*$$



# PCA 的拓展2 – Robust PCA


## □ Robust PCA

$$\min_{\hat{X}} \|X - \hat{X}\|_1 + \|\hat{X}\|_*$$




输入数据

=





低秩

+



稀疏



# PCA 的拓展2 – Robust PCA


## ▣ Robust PCA

$$\min_{\hat{X}} \|X - \hat{X}\|_1 + \|\hat{X}\|_*$$




$y \in \mathbb{R}^m$   
Test image

=



$A = [A_1 \mid A_2 \mid \cdots \mid A_k]$   
Combined  
training  
dictionary

×



$x \in \mathbb{R}^n$   
coefficients

+



$e \in \mathbb{R}^m$   
corruption,  
occlusion

## PCA 的拓展3 - 函数推广

PCA构建一组正交基，对数据进行重构

$$\begin{aligned} \sum_{i=1}^m \left\| \sum_{j=1}^{d'} z_{ij} \mathbf{w}_j - \mathbf{x}_i \right\|_2^2 &= \sum_{i=1}^m \mathbf{z}_i^T \mathbf{z}_i - 2 \sum_{i=1}^m \mathbf{z}_i^T \mathbf{W}^T \mathbf{x}_i + \text{const} \\ &\propto -\text{tr} \left( \mathbf{W}^T \left( \sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T \right) \mathbf{W} \right). \end{aligned}$$

推广到函数空间，对任意（周期）函数 $x(t)$ 进行重构

□ 构建函数正交基

□  $\{\cos n\omega t, \sin n\omega t\}, n = 0, 1, 2, \dots, \infty$

□ 优化重构系数

$$x(t) = a_0 + \sum_{n=1}^{\infty} a_n \cos n\omega t + \sum_{n=1}^{\infty} b_n \sin n\omega t$$

$$\begin{aligned} a_n &= \frac{\langle x, \cos n\omega t \rangle}{\langle \cos n\omega t, \cos n\omega t \rangle} \\ &= \frac{2}{T} \int_{t_0}^{t_0+T} x(t) \cos n\omega t \, dt \end{aligned}$$

# PCA 的拓展3 – 函数推广

傅里叶级数：推广到函数空间，对任意（周期）函数 $x(t)$ 进行重构

□ 构建函数正交基

□  $\{\cos n\omega t, \sin n\omega t\}, n = 0, 1, 2, \dots, \infty$

□ 优化重构系数

$$\begin{aligned} a_n &= \frac{\langle x, \cos n\omega t \rangle}{\langle \cos n\omega t, \cos n\omega t \rangle} \\ &= \frac{2}{T} \int_{t_0}^{t_0+T} x(t) \cos n\omega t \, dt \end{aligned}$$

$$x(t) = a_0 + \sum_{n=1}^{\infty} a_n \cos n\omega t + \sum_{n=1}^{\infty} b_n \sin n\omega t$$



$N = 0$



$N = 0$

## PCA 的拓展3 – 函数推广

傅里叶级数：推广到函数空间，对任意（周期）函数 $x(t)$ 进行重构

$$x(t) = a_0 + \sum_{n=1}^{\infty} a_n \cos n\omega t + \sum_{n=1}^{\infty} b_n \sin n\omega t$$

