

Cheat Sheet

1. 条件概率

事件的差:

$$A - B = A - AB = A\bar{B}$$

乘法公式:

$$P(AB) = P(A)P(B|A)$$

全概率公式:

$$P(B) = \sum_{i=1}^n P(BA_i) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

贝叶斯公式:

$$P(A_i|B) = \frac{P(A_i B)}{P(B)} = \frac{P(A_i)P(B|A_i)}{P(B)} = \frac{P(A_i)P(B|A_i)}{\sum_{j=1}^n P(A_j)P(B|A_j)}$$

$$\text{后验概率} = \frac{\text{先验概率} \times \text{似然度}}{\text{证据概率}}$$

独立性:

$$P(AB) = P(A)P(B)$$

2. 离散型随机变量

琴生不等式:

利用琴生不等式有, 对于连续凸函数 g 有

$$g(E(X)) \leq E(g(X))$$

例如有

$$(E(X))^2 \leq E(X^2) \text{ 和 } e^{E(X)} \leq E(e^X)$$

方差:

$$\text{Var}(X) = D(X) = E[(X - E(X))^2] = E(X^2) - [E(X)]^2$$

Bhatia-Davis 不等式:

对于 $X \in [a, b]$, 有

$$\text{Var}(X) \leq (b - E(X))(E(X) - a) \leq (b - a)^2 / 4$$

Bernoulli 分布:

分布列为 $P(X = 1) = p, P(X = 0) = 1 - p$, 记作 $X \sim \text{Ber}(p)$

有 $E(X) = p, \text{Var}(X) = p(1 - p)$

二项分布:

重复进行了 n 次 Bernoulli 试验, 记作事件 A , 随机变量 X 表示事件 A 发生的次数.

分布列为 $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$, 记作 $X \sim B(n, p)$

有 $E(X) = np, \text{Var}(X) = np(1 - p)$

用级数求和, 两边求导的方法进行计算证明. 用到二项展开式 $(1 + x)^n = \sum_{i=1}^n \binom{n}{i} x^i$

几何分布:

重复进行了 n 次 Bernoulli 试验, 记作事件 A , 随机变量 X 表示事件 A 首次发生的试验次数.

分布列为 $P(X = k) = (1 - p)^{k-1} p$, 记作 $X \sim G(p)$

有 $E(X) = \frac{1}{p}$ 和 $\text{Var}(X) = \frac{1 - p}{p^2}$

等比数列求和 $S_n = a_1 \frac{1 - q^n}{1 - q}$

依旧使用级数 $(1 - x)^{-1} = \sum_{k=1}^{\infty} x^k$ 和两边求导来证明.

几何分布拥有无记忆性: $P(X > m + n | X > m) = P(X > n)$

Pascal / 负二项分布:

重复进行了 n 次 Bernoulli 试验, 记作事件 A , 随机变量 X 表示事件 A 第 r 次发生的试验次数.

分布列为 $P(X = k) = \binom{k-1}{r-1} p^{r-1} (1-p)^{k-r} \cdot p = \binom{k-1}{r-1} p^r (1-p)^{k-r}$, 则称 X 为服从参数 p 和 r 的负二项分布.

重点在于 $(1-p)^{-r} = \sum_{t=0}^{\infty} \binom{t+r-1}{r-1} p^t$, 即 $p^{-r} = \sum_{k=r}^{\infty} \binom{k-1}{r-1} (1-p)^{k-r}$

有 $E(X) = \frac{r}{p}$ 和 $\text{Var}(X) = \frac{r(1-p)}{p^2}$

证明的时候只要想办法往概率求和等于一上转化即可.

还需要一个性质: $\frac{k}{r} \cdot \binom{k-1}{r-1} = \binom{k}{r}$

泊松分布:

分布列为 $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$, 记作 $X \sim P(\lambda)$

我们知道泰勒展开式 $e^{\lambda} = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!}$

有 $E(X) = \lambda$ 和 $\text{Var}(X) = \lambda$

泊松定理:

对任意给定的常数 $\lambda > 0$, n 为任意正整数, 设 $np = \lambda$, 则对任意给定非负整数 k 有

$$\lim_{n \rightarrow \infty} \binom{n}{k} p^k (1-p)^{n-k} = \frac{\lambda^k}{k!} e^{-\lambda}$$

对于随机变量 $X \sim B(n, p)$, 当 n 较大而 p 较小时, 令 $\lambda = np$, 则有

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}$$

即可以用泊松分布来近似计算二项分布.

3. 连续型随机变量

非负随机变量期望:

$$E[X] = \int_0^{\infty} P(X > t) dt$$

证明:

$$\text{首先观察得到 } X = \int_0^X 1 dt = \int_0^{\infty} 1(X > t) dt$$

$$\begin{aligned} E[X] &= E\left[\int_0^{\infty} 1(X > t) dt\right] \\ &= \int_{-\infty}^{+\infty} \int_0^{\infty} 1(x > t) f(x) dt \\ &= \int_0^{+\infty} \left[\int_{-\infty}^{+\infty} 1(X > t) f(x) dx \right] dt \\ &= \int_0^{+\infty} \left[\int_{-\infty}^t 1(X > t) f(x) dx + \int_t^{+\infty} 1(X > t) f(x) dx \right] dt \\ &= \int_0^{+\infty} \left[\int_t^{+\infty} f(x) dx \right] dt \\ &= \int_0^{+\infty} P(X > t) dt \end{aligned}$$

均匀分布:

$$\text{概率密度 } f(x) = \frac{1}{b-a}, x \in [a, b], \text{ 则记作 } X \sim U(a, b)$$

$$\text{而分布函数则为 } F(x) = \frac{x-a}{b-a}, a < x < b$$

$$\text{期望和方差分别为 } E(X) = \frac{a+b}{2}, \text{Var}(X) = \frac{(b-a)^2}{12}$$

指数分布:

$$f(x) = \lambda e^{-\lambda x}, x \geq 0, \text{ 而 } F(x) = 1 - e^{-\lambda x}, \text{ 记作 } X \sim e(\lambda)$$

$$\text{期望和方差为 } E(X) = \frac{1}{\lambda}, \text{Var}(X) = \frac{1}{\lambda^2}$$

证明用分部积分法.

指数分布具有无记忆性, 且是唯一具有无记忆性的连续型随机变量:

$$P(X > s+t | X > t) = P(X > s)$$

正态分布:

概率密度为 $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$, 记作 $X \sim N(\mu, \sigma^2)$

标准正态分布为 $f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$, 记作 $X \sim N(0, 1)$

期望和方差为 $E(X) = \mu, \text{Var}(X) = \sigma^2$

正态分布的估计:

对于标准正态分布 $X \sim N(0, 1)$ 和任意 $\epsilon > 0$, 有

$$P(X \geq \epsilon) \leq \frac{1}{2} e^{-\frac{\epsilon^2}{2}}$$

还有 $P(|X| \geq \epsilon) \leq \min\{1, \sqrt{\frac{2}{\pi}} \frac{1}{\epsilon} e^{-\frac{\epsilon^2}{2}}\}$

4. 多维随机变量及其分布

随机变量独立性:

$$F(x, y) = F_X(x)F_Y(y)$$

对于离散型随机变量来说, 即等价于 $p_{i,j} = p_{i \cdot} p_{\cdot j}$

对于连续型随机变量来说, 即等价于 $f(x, y) = f_X(x)f_Y(y)$

二维正态分布:

$$\text{令 } \mu = \begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix} \text{ 和 } \Sigma = \begin{pmatrix} \sigma_x^2 & \rho\sigma_x\sigma_y \\ \rho\sigma_x\sigma_y & \sigma_y^2 \end{pmatrix}$$

则 X 和 Y 的联合概率密度函数为

$$f(x, y) = (2\pi)^{-2/2} |\Sigma|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\xi - \mu)^T \Sigma^{-1}(\xi - \mu)\right)$$

$$\text{其中 } \Sigma^{-1} = \frac{1}{(1 - \rho^2)\sigma_x^2\sigma_y^2} \begin{pmatrix} \sigma_y^2 & -\rho\sigma_x\sigma_y \\ -\rho\sigma_x\sigma_y & \sigma_x^2 \end{pmatrix}$$

极大极小分布:

假设 X, Y 相互独立.

极大分布:

$$F_Z(z) = P(Z \leq z) = P(\max(X, Y) \leq z) = P(X \leq z, Y \leq z) = F_X(z)F_Y(z)$$

极小分布:

$$F_Z(z) = 1 - (1 - F_X(z))(1 - F_Y(z))$$

和的分布:

对于 $Z = X + Y$,

$$\text{通用的有 } F_Z(z) = \iint_{x+y \leq z} f(x, y) dx dy = \int_{-\infty}^{+\infty} dx \int_{-\infty}^z f(x, u-x) du = \int_{-\infty}^z \int_{-\infty}^{+\infty} f(x, u-x) dx du$$

$$\text{两边求导可得 } f_Z(z) = \int_{-\infty}^{+\infty} f(x, z-x) dx$$

假设 X, Y 相互独立, 有著名的卷积公式

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx = \int_{-\infty}^{+\infty} f_X(z-y) f_Y(y) dy$$

乘除的分布:

$$f_{XY}(z) = \int_{-\infty}^{+\infty} \frac{1}{|x|} f(x, \frac{z}{x}) dx$$

$$f_{X/Y}(z) = \int_{-\infty}^{+\infty} |x| f(x, xz) dx$$

联合分布函数:

设有 $U = u(X, Y), V = v(X, Y)$

$$f_{UV}(u, v) = f_{XY}(x(u, v), y(u, v)) \begin{vmatrix} \frac{\partial u}{\partial x} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y} \end{vmatrix}$$

多维随机变量柯西不等式:

$$E[XY] \leq \sqrt{E[X^2]E[Y^2]}$$

协方差:

定义协方差为 $\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$

则有 $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$

对任意 X_1, X_2, Y 还有性质 $\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$

并且 $\text{Cov}(aX, bY) = ab\text{Cov}(X, Y)$

若 X 和 Y 独立, 则 $\text{Cov}(X, Y) = 0$, 反之则不然.

协方差不等式:

$[\text{Cov}(X, Y)]^2 \leq \text{Var}(X)\text{Var}(Y)$, 当且仅当 $Y = aX + b$ 等号成立.

相关系数:

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

条件概率:

$$\text{先有 } f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$$

$$\text{再有 } F_{X|Y}(x|y) = P(X \leq x | Y = y) = \int_{-\infty}^x f_{X|Y}(u|y) du$$

乘法公式:

$$f(x, y) = f_X(x)f_{Y|X}(y|x) = f_Y(y)f_{X|Y}(x|y)$$

5. 集中不等式

Markov 不等式:

对任意随机变量 $X \geq 0, \epsilon > 0$, 有

$$P(X \geq \epsilon) \leq \frac{E(X)}{\epsilon}$$

证明:

$$E[X] = E[X | X \geq \epsilon]P(X \geq \epsilon) + E[X | X \leq \epsilon]P(X \leq \epsilon) \geq \epsilon P(X \geq \epsilon)$$

推论: 对于单调增的非负函数 g 有 $P(X \geq \epsilon) \leq \frac{E[g(X)]}{g(\epsilon)}$

Chebyshev 不等式:

$$P(|X - \mu| > \epsilon) \leq \frac{\text{Var}(X)}{\epsilon^2}$$

Cantelli 不等式:

$$P(X - \mu \geq \epsilon) \leq \frac{\sigma^2}{\sigma^2 + \epsilon^2} \text{ 和 } P(X - \mu \leq -\epsilon) \leq \frac{\sigma^2}{\sigma^2 + \epsilon^2}$$

证明过程中令 $Y = X - \mu$, 并添加了一个 t 变量, 用以之后求最值.

Chebyshev 不等式推论:

独立同分布随机变量 $E[X_i] = \mu, \text{Var}(X_i) \leq \sigma^2$

$$P(|\frac{1}{n} \sum_{i=1}^n X_i - \mu| \geq \epsilon) \leq \frac{\sigma^2}{n\epsilon^2}$$

Young 不等式:

对于 $\frac{1}{p} + \frac{1}{q} = 1$, 有

$$ab \leq \frac{1}{p}a^p + \frac{1}{q}b^q$$

Holder 不等式:

$$E[|XY|] \leq (E[|X|^p])^{\frac{1}{p}} (E[|Y|^q])^{\frac{1}{q}}$$

Chernoff 不等式:

矩生成函数为 $M_X(t) = E[e^{tX}]$

Chernoff 方法为:

$$P(X \geq E[X] + \epsilon) = P(e^{tX} \geq e^{tE[X] + t\epsilon}) \leq e^{-t\epsilon - tE[X]} E[e^{tX}]$$

Chernoff 引理:

对于 $X \in [0, 1]$ 的期望 $\mu = E[X]$, 对任意 $t > 0$ 有

$$E[e^{tX}] \leq \exp(t\mu + \frac{t^2}{8})$$

使用凸函数性质 $e^{tX} = e^{tX + (1-X)0} \leq Xe^t + (1-X)e^0$

因此对 $X \in [a, b]$ 有 $E[e^{tX}] \leq \exp(\mu t + \frac{t^2(b-a)^2}{8})$

亚高斯随机变量:

将有界随机变量和高斯随机变量统一起来.

若 X 满足 $E[e^{(X-E[X])t}] \leq \exp(\frac{bt^2}{2})$

则称为亚高斯随机变量.

高斯分布是参数为 σ^2 的亚高斯分布.

对于满足 $E[X_i] = 0$ 的亚高斯随机变量有

$$E[\max_{i \in [n]} X_i] \leq \sqrt{2b \ln n}$$

根据 Jensen 不等式有 $\exp(tE[\max_{i \in [n]} X_i]) \leq E[\exp(t \max_{i \in [n]} X_i)]$

6. 大数定理以及中心极限定理

依概率收敛:

$$\lim_{n \rightarrow \infty} P(|X_n - a| < \epsilon) = 1 \text{ 或 } \lim_{n \rightarrow \infty} P(|X_n - a| \geq \epsilon) = 0$$

则称 $\{X_n\}$ 依概率收敛于 a , 记作 $X_n \xrightarrow{P} a$

大数定律:

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \frac{1}{n} \sum_{i=1}^n E[X_i]$$

$$\text{即看 } P(|\frac{1}{n} \sum_{i=1}^n (X_i - E[X_i])| \geq \epsilon) \rightarrow 0$$

Markov 大数定律:

$$\frac{1}{n^2} \text{Var}(\sum_{i=1}^n X_i) \rightarrow 0$$

Chebyshev 大数定律:

$$\text{Var}(X_n) \leq c \text{ 即 } \frac{c}{n\epsilon^2} \rightarrow 0$$

辛钦大数定律:

每个随机变量的期望 $E[X_i] = \mu$ 存在.

Bernoulli 大数定律:

对于 $X_n \sim B(n, p)$ 可以看作是一系列的 Bernoulli 随机变量, 然后就有 $\frac{X_n}{n} \xrightarrow{P} p$

判断随机变量序列满足大数定律:

独立同分布, 则用辛钦大数定律; 否则用 Markov 大数定律.

依分布收敛:

$$\lim_{n \rightarrow \infty} F_{Y_n}(y) = F_Y(y)$$

中心极限定理:

对于独立同分布的随机变量 $X_1, X_2, \dots, X_n, \dots$ 的期望 $E[X_i] = \mu$ 和方差 $\text{Var}(X_i) = \sigma^2$

$$\text{则 } Y_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1)$$

变形公式为:

$$\sum_{i=1}^n X_i \xrightarrow{d} N(n\mu, n\sigma^2) \text{ 和 } \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{d} N(\mu, \frac{\sigma^2}{n})$$

7. 统计基本概念

样本均值:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{且有 } E[\bar{X}] = \mu, \text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \bar{X} \xrightarrow{d} N(\mu, \frac{\sigma^2}{n})$$

样本方差:

$$S_0^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

$$\text{则有 } E[S_0^2] = \frac{n-1}{n} \sigma^2$$

修正后的样本方差:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \text{ 即 } S^2 = \frac{n}{n-1} S_0^2$$

则有 $E[S^2] = \sigma^2$

样本 k 阶原点矩:

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

样本 k 阶中心矩:

$$A_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

第 k 次序统计量:

$$F_k(x) = \sum_{r=k}^n \binom{n}{r} [F(x)]^r [1 - F(x)]^{n-r}$$

$$f_k(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x)$$

Beta 函数:

$$\text{Beta}(\alpha_1, \alpha_2) = \int_0^1 x^{\alpha_1-1} (1-x)^{\alpha_2-1} dx$$

Gamma 函数:

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx$$

$$\Gamma(1) = 1, \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}, \Gamma(\alpha) = (\alpha-1)\Gamma(\alpha-1), \Gamma(n+1) = n!$$

$$\text{Beta}(\alpha_1, \alpha_2) = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1 + \alpha_2)}$$

$$\text{Beta}(\alpha_1, \alpha_2) = \frac{\alpha_1 - 1}{\alpha_1 + \alpha_2 - 1} \text{Beta}(\alpha_1 - 1, \alpha_2)$$

Beta 分布:

$$f(x) = \frac{x^{\alpha_1-1}(1-x)^{\alpha_2-1}}{\text{Beta}(\alpha_1, \alpha_2)}, x \in (0, 1)$$

记作 $X \sim B(\alpha_1, \alpha_2)$

$$\text{有 } E[X] = \frac{\alpha_1}{\alpha_1 + \alpha_2}, \text{Var}(X) = \frac{\alpha_1 \alpha_2}{(\alpha_1 + \alpha_2)^2 (\alpha_1 + \alpha_2 + 1)}$$

均匀分布第 k 次序统计量:

若 X_1, X_2, \dots, X_n 服从 $U(0, 1)$, 则

$$X_{(k)} \sim B(k, n - k + 1)$$

Gamma 分布:

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, x > 0$$

记作 $X \sim \Gamma(\alpha, \lambda)$

$$\text{有 } E[X] = \frac{\alpha}{\lambda}, \text{Var}(X) = \frac{\alpha}{\lambda^2}$$

和指数分布比较类似.

Gamma 分布具有可加性: $X + Y \sim \Gamma(\alpha_1 + \alpha_2, \lambda)$

特别的, $X \sim \Gamma(\frac{1}{2}, \frac{1}{2})$ 有 $f(x) = \frac{1}{\sqrt{2\pi}} x^{-\frac{1}{2}} e^{-\frac{1}{2}x}, x > 0$

且有若 $X \sim N(0, 1)$, 则 $X^2 \sim \Gamma(\frac{1}{2}, \frac{1}{2})$

卡方分布:

若 X_1, X_2, \dots, X_n 是来自总体 $X \sim N(0, 1)$ 的一个样本, 称 $Y = X_1^2 + X_2^2 + \dots + X_n^2$ 为服从自由度为 n 的 χ^2 分布, 记作 $Y \sim \chi^2(n)$

所以也就有 $Y \sim \Gamma(\frac{n}{2}, \frac{1}{2})$

$$E[Y] = n, \text{Var}(Y) = 2n$$

可加性: $X + Y \sim \chi^2(m + n)$

若随机变量 $X \sim N(0, 1)$, 则 $E[X^k] = \begin{cases} (k-1)!!, & k \text{ is even} \\ 0, & k \text{ is odd} \end{cases}$

t 分布:

设 $X \sim N(0, 1)$ 和 $Y \sim \chi^2(n)$ 相互独立, 则称

$$T = \frac{X}{\sqrt{Y/n}} \text{ 服从自由度为 } n \text{ 的 } t \text{ 分布, 记作 } T \sim t(n)$$

F 分布:

设随机变量 $X \sim \chi^2(m)$ 和 $Y \sim \chi^2(n)$ 相互独立, 则称

$$F = \frac{X/m}{Y/n} \text{ 为服从自由度 } m, n \text{ 的 } F \text{ 分布, 记作 } F \sim F(m, n)$$

五大抽样定理其一:

设 X_1, X_2, \dots, X_n 是来自总体 $N(\mu, \sigma^2)$ 的样本, 则有

$$\bar{X} = \sum_{i=1}^n X_i \sim N(\mu, \frac{\sigma^2}{n}), \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

在知方差 σ 时能用于估计 μ ; 知期望 μ 时能用于估计 σ^2 .

五大抽样定理其二:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$\text{则有 } \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

$$\text{即 } \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1)$$

能用于估计方差 σ^2

五大抽样定理其三:

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

可用于估计期望 μ

五大抽样定理其四:

设 X_1, X_2, \dots, X_m 和 Y_1, Y_2, \dots, Y_n 分别来自总体 $N(\mu_X, \sigma^2), N(\mu_Y, \sigma^2)$, 其中两者方差一致, 则

$$\frac{\bar{X} - \bar{Y} - (\mu_X - \mu_Y)}{\sqrt{\frac{(m-1)S_X^2 + (n-1)S_Y^2}{m+n-2}} \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(m+n-2)$$

五大抽样定理其五:

设 X_1, X_2, \dots, X_m 和 Y_1, Y_2, \dots, Y_n 分别来自总体 $N(\mu_X, \sigma_X^2), N(\mu_Y, \sigma_Y^2)$, 其中两者方差不一定一致, 则

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F(m-1, n-1)$$

分位点:

给定 $\alpha \in (0, 1)$ 和随机变量 X , 称 $P(X > \lambda_\alpha) = \alpha$ 的实数 λ_α 为上侧 α 分位点.

8. 参数估计

矩估计:

使用样本 k 阶矩和样本 k 阶中心矩相等进行估计.

最大似然估计

$$\text{似然函数 } L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n P(x_i; \theta)$$

$$\text{取其对数 } \ln L(\theta) = \sum_{i=1}^n \ln P(x_i; \theta) \text{ 然后进行求导等于零}$$

并令其等于零, 即可解出 $\hat{\theta}$

我们有 $\hat{\mu} = \mu(\hat{\theta})$ 是 μ 的最大似然估计.

无偏性:

$$E[\hat{\theta}(X_1, X_2, \dots, X_n)] = \theta$$

则 $\hat{\theta}$ 是 θ 的无偏估计.

有效性:

$$\text{Var}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

一般方差越小, 无偏估计越好.

